

1 Rappresentazione posizionale

Per rappresentare un qualsiasi numero $N \geq 1$ in notazione posizionale usando una base β (dove β = numero di simboli $S - 1$) si può stabilire la relazione

$$N = (c_p c_{p-1}, \dots c_0)_\beta = (c_p \beta^p c_{p-1} \beta^{p-1} \dots c_0).$$

Per un numero $\alpha < 1$ si ha $\alpha = (0.c_p c_{p-1}, \dots c_0)_\beta$ rappresentabile anche come la sommatoria $\sum_{i=1}^{\infty} a_i \beta^{-i}$ quindi si ha che un qualsiasi numero $\alpha \in \mathbb{R}$ è rappresentabile come

$$\alpha = \sum_{i=1}^{\infty} a_i \beta^{-i} \beta^p$$

dove p è il numero di simboli dopo il punto radice $\neq 0$.

Riassumendo: un qualsiasi numero $\alpha \in \mathbb{R}$ è rappresentabile in notazione **Posizionale** come $\text{segno}(\alpha) m \beta^p$ dove $m = \sum_{i=1}^{\infty} a_i \beta^{-i}$

2 Rappresentazione floating point

Per memorizzare un qualsiasi numero reale ma in uno spazio finito di memorie viene utilizzata la rappresentazione a **virgola mobile** che a differenza di altre rappresentazioni (es. virgola fissa) permette grande flessibilità. il formato di rappresentazione è caratterizzato da 4 elementi:

$$\beta, t, L, U$$

- β è la base usata, di norma base 2.
- t è il numero massimo di numeri dedicato alla rappresentazione della mantissa, di norma **single precision** = 23 **double precision** = 52.
- L, U sono rispettivamente il **Lower** e **Upper bound** per la rappresentazione di un esponente r quindi il numero minimo e massimo che si può rappresentare, di norma $[-127, +128]$.

altre caratteristiche del insieme dei numeri floating point

- è un insieme **discreto** e **finito**.
- è **simmetrico** all'origine, quindi per ogni numero esiste l'opposto.
- la sua cardinalità è data da $\text{card}(\beta, t, L, U) = 2(\beta - 1)\beta^{t-1}(U - L + 1)$ dove
 - $(U - L + 1)$ è il numero di tutti i possibili esponenti
 - β^{t-1} è il numero di tutti i valori che ogni posizione dedicata alla mantissa può prendere escluso un elemento.
 - $\beta - 1$ è il numero che il primo elemento può prendere (-1 perchè non può essere zero).
 - 2 perchè un valore può essere sia positivo che negativo.

3 Errori di macchina e operazioni

Dato che l'insieme dei **Floating point** è un insieme discreto e finito spesso si fa uso di **troncamento** e **arrotondamento** per rappresentare i numeri non appartenenti all'insieme di riferimento ottenendo una perdita di informazione chiamata **errore**.

L'**errore assoluto** nella rappresentazione di un numero α è la differenza tra il numero e la sua rappresentazione, quindi si ottiene che: $E_a = |\alpha - \alpha^*|$ dove α^* è la rappresentazione macchina.

L'errore relativo invece è dato da $E_r = \frac{E_a}{|\alpha|}$. Inoltre si ha che l'errore relativo ottenuto è sempre minore o uguale alla **precisione di macchina** rappresentata come $k\beta^{t-1}$ dove

- $k = 1$ nel caso si utilizzino logiche di approssimazione tramite troncamento.
- $k = \frac{1}{2}$ nel caso si usi arrotondamento.

questo risultato è chiamato **teorema dell'errore di rappresentazione dei numeri reali**.

Dato che l'insieme dei floating point F non è chiuso alle operazioni aritmetiche si possono verificare, oltre ai casi di **overflow** e **underflow**, dei casi in cui il numero non è rappresentabile pur essendo compreso tra il numero massimo e il numero minimo rappresentabile dell'insieme, infatti si ha che un'operazione tra numeri floating point restituisce un numero reale che andrà trasformato seguendo la logica vista nel capitolo Rappresentazione floating point